

# السلاسل الزمنية

## Time Series

إعداد محمد عثمان


عالم بيانات



## الفصل الأول

# نظرة عامة عن السلاسل الزمنية

## Time-Series Analysis



تقيس معظم الشركات حول العالم شيئًا ما بمرور الزمن وذلك لأغراض عديدة أبرزها التعرف على أداء خدمات الشركة ومواردها بهدف الاستمرارية ، النمو والتحسين، أو توقع وإدارة المخاطر التي قد تواجه الشركة في المستقبل .

على سبيل المثال تقوم الشركات بقياس معدل المبيعات، الإيرادات، استهلاك الموارد كاستهلاك الطاقة اليومي، الشهري، أو السنوي وذلك لتعزيز أدائها وتحقيق أكبر استفادة.

هذه القياسات المرتبطة بعامل الزمن تسمى بالسلاسل الزمنية Time series


تعد مهارة تحليل السلاسل الزمنية أمرًا مهمًا لأي محلل أو عالم بيانات حتى المبتدئين منهم!

## ماهي السلاسل الزمنية Time Series

**السلسلة الزمنية Time Series:** هي عبارة عن تسلسل من القيم (نقاط بيانية) منظمة بترتيب زمني ثابت .


- التسلسل يلتقط البيانات في نقاط زمنية متباعدة بشكل متساوٍ
- البيانات المجمعة بشكل غير منتظم زمنيًا لا تعتبر سلسلة زمنية!

**مثال:** يتم رصد عدد الزيارات لموقع الكتروني يوميًا عند الساعة 04:00 مساءً



## مثال واقعي لسلسلة زمنية

لنلقي نظرة على مثال واقعي يمثل مبيعات المركبات خفيفة الوزن بآلاف الوحدات على مدى سنوات:



### ملاحظات السلسلة الزمنية :

- المحور x يمثل الزمن (تاريخ المبيعات من 1976 - 2022)
- المحور y يمثل عدد السيارات المباعة بالولايات المتحدة بآلاف
- بيانات السلسلة الزمنية مجمعة على مدى 40 سنة تقريبًا على فترات شهرية
- تذبذب المبيعات بين 0.6 مليون و 1.8 مليون سيارة




# تحليل السلسلة الزمنية Time Series Decomposition

لتحليل أي سلسلة زمنية يتوجب أن نتعرف على ثلاث مفاهيم رئيسة مُكوّنة للسلسلة الزمنية :



# تحليل السلسلة الزمنية Time Series Decomposition

1- الاتجاه Trend : وهو التوجه العام للسلسلة الزمنية ، على سبيل المثال هل المبيعات في تزايد أم في تناقص أم هي في حالة ثابتة عبر الزمن.



يمكن أن تصنف أنواع الاتجاه في السلسلة الزمنية إلى:


- **اتجاه تصاعدي Uptrend** : يُظهر تحليل السلاسل الزمنية نمطًا عامًا صاعدًا لنسنتج اتجاهًا تصاعديًا.
- **اتجاه تنازلي Downtrend** : يوضح تحليل السلاسل الزمنية نمطًا تنازليًا لنسنتج اتجاهًا تنازليًا.
- **اتجاه أفقي أو ثابت Stationary trend** : إذا لم يتم ملاحظة أي نمط ، فإنه يسمى اتجاه أفقي أو ثابت.

# تحليل السلسلة الزمنية Time Series Decomposition

## 2- الموسمية Seasonality : تمثل الموسمية التغيرات في السلوك التي تظهر خلال موسم واحد بشكل متكرر

أي هو نمط يتكرر خلال فترة زمنية معينة !

والمقصود بالموسم هنا ، الجزء الزمني من زمن أكبر يمثل دورة زمنية كاملة على سبيل المثال في أشهر الشتاء تقل مبيعات المثلجات في أحد متاجر التجزئة بشكل ملحوظ (أشهر الشتاء جزء من السنة) مثال آخر ، خلال أيام العطلة الأسبوعية ( الجمعة ، السبت ) تزداد نسبة الزحام المروري في المدينة (أيام العطلة جزء من الأسبوع).




الموسمية يمكن أن تأخذ الأشكال التالية :

- (جزء من الساعة) في أول 20 دقيقة من كل ساعة
- (جزء من اليوم) ساعة من أصل 24 ساعة
- (جزء من أسبوع) يوم في الأسبوع
- (جزء من الشهر) العشرية الأولى من الشهر
- (جزء من سنة) الربع الأول من السنة أو أشهر الصيف

الأمثلة كثيرة وبإمكانك القياس على ذلك لاستنتاج أمثلة أخرى.



# تحليل السلسلة الزمنية Time Series Decomposition




ما يمكن ملاحظته من التصوير البياني أنه يتغير سلوك السلسلة الزمنية بشكل ملحوظ كل 5 دقائق تقريبًا هبوطًا ونزولًا من 90 – 110 من حيث الطلب على الكهرباء

تصوير بياني يمثل الموسمية مقابل الزمن بالدقائق لمقدار الطلب على محطة طاقة كهربائية

## تحليل السلسلة الزمنية Time Series Decomposition

3- البواقي **Residuals** هو الجزء المتبقي من تحليل السلسلة الزمنية بعد استخراج (فصل) كل من الاتجاه **Trend** و الموسمية **Seasonality**.




هذا التصوير البياني والذي يمثل البواقي ناشئ عن عملية فصل كل من الاتجاه والموسمية عن السلسلة الزمنية الأصلية

## مثال واقعي لسلسلة زمنية

الآن لنعد إلى مثالنا السابق ولكن هذه المرة سنقوم باستكشاف السلسلة الزمنية باستخدام لغة بايثون Python وتحليلها إلى مكوناتها الأساسية كما شرحنا سابقًا.

سننطلق إلى شرح عملية التحليل باستخدام بايثون في فصول لاحقة ، ما يهمنا الآن التعرف على فكرة التحليل فقط !




لتحميل البيانات قم بزيارة الموقع عبر الارتباط التالي :

[Light Weight Vehicle Sales](#) •

# مثال واقعي لسلسلة زمنية

تحليل السلسلة الزمنية الخاصة بمبيعات المركبات خفيفة الوزن بآلاف الوحدات



السلسلة الزمنية الأصل  
Original Time Series

اتجاه ثابت  
Stationary trend

الموسمية  
Seasonality


البواقي  
Residuals

# استخدامات السلاسل الزمنية

لقد ذكرنا بالفعل أن معظم الشركات تجمع نوعًا من البيانات بمرور الوقت. لكن لماذا؟ لنستعرض حالتين من حالات الاستخدام.

## 1- تحليل الأنماط Patterns Analysis

لا يمكن الكشف بسهولة عن العديد من الأنماط والعلاقات في بيانات السلاسل الزمنية بالنظر فقط إلى الأرقام الأولية، عوضًا عن ذلك يتم تصوير هذه السلاسل على هيئة مخططات بيانية كما رأينا سابقًا لتسهيل عملية استخراج الأنماط. مكتبة **Stumpy** هي أحد الأدوات المثالية لهذه للوظيفة – وسوف نتعمق بالتفاصيل الدقيقة لاحقًا، في الوقت الحالي، ما عليك سوى إلقاء نظرة على الشكل التالي مراقبة النمط المتكرر بالسلسلة:




يوضح الشكل المناطق المظلمة باللون الرمادي لنمط متكرر في سلسلة زمنية

# استخدامات السلاسل الزمنية

## 2- اكتشاف الشذوذ Anomaly Detection

توفر مكتبة **Stumpy** أيضًا طريقة لاكتشاف **الحالات الشاذة** في السلاسل الزمنية باختصار ، فإن الانحراف هو قيمة تختلف بشدة عن أي شيء تتوقعه. يعد اكتشاف الانحرافات في القيم الموزعة بشكل طبيعي أمرًا سهلًا مثل عزل السجلات الموجودة في بعض الانحرافات المعيارية عن المتوسط ، ولكنه ليس بهذه السهولة مع بيانات السلاسل الزمنية.




يوضح الشكل اكتشاف بيانات شاذة عن السلوك الطبيعي للسلسلة الزمنية مظللة باللون الأحمر

# استخدامات السلاسل الزمنية

## 3- التوقعات العامة General forecasting

أحد الأسباب الأكثر وضوحًا لجمع بيانات السلاسل الزمنية هو عمل تنبؤات مستقبلية. لحسن الحظ ، توفر `Python` تقنيات عديدة قد تبدو الاختصارات مثل `AR`, `MA`, `EXSM`, `ARMA`, `ARIMA`, `SARIMA`, `SARIMAX`, `VAR`, `VARMA`, `RNN`, `LSTM`, `GRU` وكأنها لغة أجنبية لا داعي للقلق سنطلع عليها في الفصول اللاحقة .



يوضح الشكل آخر 20 سنة من البيانات لمبيعات السيارات وسنتين من التوقعات المستقبلية:

# ما هي الخيارات التي توفرها بايثون لتحليل السلاسل الزمنية؟

لغة بايثون هي أحد أهم الأدوات اليوم في معظم الأمور التي تتعلق بالبيانات و تحليل السلاسل الزمنية لا يعد استثناءً , فيما يلي قائمة بالمكتبات التي سنستخدمها مع وصف موجز لحالات الاستخدام:

- **Pandas** : مكتبة أساسية لتحليل البيانات. تتيح لك العمل مع فهارس التاريخ والوقت والنطاقات الزمنية **date-time indexes** بكفاءة وإجراء تحويلات مثل التغيير والتأخير والتجميع وغير ذلك الكثير.
- **Statsmodels** : مكتبة للنمذجة الإحصائية تسمح لك باستخدام نماذج إحصائية تتراوح من المتوسط المتحرك البسيط إلى الانحدار التلقائي المتجه و الموسمي **simple moving average to seasonal and vector autoregression** . يمكنك أيضًا استخدامه لاختبار الثبات **Stationarity**.
- **Scikit-Learn** : مكتبة عامة للتعلم الآلي **ML** لا تأتي مع أي خوارزميات محددة للسلاسل الزمنية، ولكن يمكن استخدام أي خوارزميات انحدار **Regression Algorithms** للتنبؤ بالسلسلة الزمنية إذا تمت إعادة صياغة السلسلة الزمنية كمشكلة تعلم آلي خاضعة للإشراف.



## ما هي الخيارات التي توفرها بايثون لتحليل السلاسل الزمنية؟

- **TensorFlow** : مكتبة التعلم العميق الأكثر شهرة في لغة بايثون تستخدم لاستكشاف كيف يمكن استخدام الشبكات العصبية المتكررة **RNN** وتفرعاتها **GRU LSTM** للتنبؤ بالسلسلة الزمنية. سنستعرض أيضًا بعض الاستخدامات الأساسية للشبكات العصبية التلافيفية **CNN** في التسلسل الزمني.
- **XGBoost** : هي خوارزمية هيمنت مؤخرًا على التعلم الآلي التطبيقي ومسابقات **Kaggle** للبيانات المنظمة أو الجدولية وقد أثبتت قوتها في مجال التنبؤ بالسلاسل الزمنية حتى أنها ضاهت خوارزميات التعلم العميق.
- **Prophet** : مكتبة التنبؤ بالسلاسل الزمنية من شركة **Meta** (فيسبوك سابقًا) تعتمد على نماذج مضافة سنستكشف أيضًا الشقيق الأكبر لهذه المكتبة **Neural Prophet**.
- **Stumpy** : مكتبة تقوم بشكل أساسي بحساب الـ **profile matrix** بكفاءة ، والتي يمكن استخدامها بعد ذلك للكشف عن الأنماط والشذوذ **Patterns and Anomaly Detection**.
- **PyCaret** : مكتبة رائعة للتعلم الآلي، والتي أصبحت تدعم السلاسل الزمنية.

- [Time Series From Scratch — Seeing The Big Picture](#)
- [What is a trend in time series?](#)
- [Light Weight Vehicle Sales \(LTOTALNSA\)](#)
- [How to Identify and Remove Seasonality from Time Series Data with Python](#)
- [Specialized Models: Time Series and Survival Analysis by IBM](#)